SiemDiag : assistant RAG pour le diagnostic de composants Siemens

Arthur NEUEZ, Laura MERGEL, Soufiane FIKRI

Projet NLP : agent conversationnel spécialisé, Qwen 2.5 3B Instruct, RAG hybride et fine-tuning LoRA

1. Introduction (cas d'usage et présentation du projet)

SiemDiag est un agent conversationnel destiné aux techniciens de maintenance d'automates **Siemens SIMATIC S7-1200 / S7-1500** et de variateurs **SINAMICS G120**. Il répond en français à une question technique (un code défaut, une LED qui clignote, un paramètre à régler) uniquement à partir de la documentation constructeur. Chaque information est suivie de sa source (manuel, édition, pages). Quand la réponse n'est pas dans les extraits, l'agent répond exactement `Information absente de la documentation fournie.`, sans inventer. Cette règle couvre aussi les questions proches du corpus.

Le projet a été construit par étapes dans un notebook Colab (GPU T4). On observe d'abord le modèle, puis on construit et règle une baseline. On ajoute ensuite une pipeline RAG sur le corpus réel, puis on fine-tune le modèle par LoRA et on compare la baseline au modèle fine-tuné. Les figures et tableaux sont regroupés en annexe.

- **LLM** : `Qwen/Qwen2.5-3B-Instruct` (Hugging Face), multilingue, chargé en 4 bits NF4 avec double quantification (bitsandbytes) pour tenir dans quelques Go de VRAM.
- **Recherche** : embeddings `intfloat/multilingual-e5-base`, re-ranker cross-encoder `BAAI/bge-reranker-v2-m3`, index FAISS et BM25.
- **Corpus** : 13 manuels Siemens en français et en anglais, téléchargés sur le portail officiel Siemens Industry Online Support. Nous avons découpé les PDF en amont en **6 068 passages** (3 931 en anglais, 2 137 en français) dans `chunks.jsonl`.

2. Baseline

La baseline (`BaselineAgent`) est le modèle sans fine-tuning, entouré du code qui gère la conversation. Elle comprend un prompt système, un historique limité aux 3 derniers tours (pour éviter que le contexte n'explose, un tour étant une question de l'utilisateur et la réponse de l'agent), l'injection optionnelle d'exemples few-shot jamais tronqués hors du contexte, et tous les paramètres de génération configurables (300 tokens au maximum par réponse). Les extraits de documentation sont ajoutés au message envoyé, mais pas à l'historique.

Protocole. Avant de brancher le vrai corpus, on simule un RAG avec un mini-manuel fictif de pompe industrielle (sections §3.2 à §8.1, avec deux avertissements de sécurité), pour voir comment la baseline se comporte. On pose 15 questions : 9 dont la réponse est dans le contexte et 6 hors contexte, dont 3 pièges proches du texte (par exemple, demander le code E08 alors que seuls E04 et E07 existent). La notation est automatique : exactitude (éléments attendus

présents), citation de la bonne section, reprise de l'avertissement, faux refus, refus correct, refus au format exact et cohérence entre 3 seeds.

Test 1 : zero-shot ou few-shot. Les deux modes obtiennent 100 % d'exactitude, aucun faux refus et 100 % de refus corrects, en échantillonnage Argmax. La différence porte sur la sécurité : le few-shot produit des réponses plus courtes (71 caractères en moyenne contre 117) mais ne reprend l'avertissement que dans 50 % des cas, contre 100 % en zero-shot. Les exemples ont rendu le modèle plus concis au détriment des consignes de sécurité.

Test 2 : paramètres de décodage. On fait varier un paramètre à la fois autour de la configuration par défaut de Qwen ($T = 0{,}7$, $k = 20$, $p = 0{,}8$), en few-shot avec 3 seeds (Fig. 1). Les configurations les plus resserrées ($T \leq 0{,}3$, $k = 1$, $p = 0{,}5$) restent à 100 % partout. Dès que l'échantillonnage s'ouvre, des erreurs apparaissent. À $T = 1{,}5$ ou $p \geq 0{,}95$, on observe un faux refus (4 %), une exactitude qui descend à 96 %, et des réponses qui changent d'un seed à l'autre (cohérence à 93 %). La citation descend à 96 % dès que $k \geq 5$ ou $T \geq 0{,}7$.

Configuration retenue : zero-shot avec décodage greedy (argmax, T = 0). C'est la seule configuration à 100 % sur toutes les métriques, sécurité comprise. Elle est déterministe, donc reproductible. Ce mini-banc de test sature vite (presque tout est à 100 %) : il sert surtout à orienter nos choix de réglage pour la suite, en évitant les réglages risqués. Il ne prédit pas le comportement sur le corpus réel, beaucoup plus difficile. Nous avons donc retenu cette configuration pour toute la suite.

3. Pipeline RAG

3.1. Corpus et architecture

Chaque passage du corpus a un type : `entry` (1 669 passages : un défaut, une alarme ou un paramètre complet des List Manuals, avec cause et remède), `table` (1 179, jamais coupés, entête répété), `text` (2 210, environ 350 mots avec 50 mots de recouvrement, sans franchir un chapitre) et `figure` (1 010 : légende, libellés et OCR d'un schéma). Le texte indexé (`text_embed`) est précédé du titre du manuel et du chapitre, pour qu'un passage « Cause : … » reste rattaché à son sujet.

L'architecture (Fig. 2) suit ces étapes :

1. **Reformulation** : une question de suivi (Exemple : « Et comment je l'acquitte ? ») est réécrite par Qwen pour faire sens individuellement (sans reposer sur l'historique), à partir des 4 derniers messages.
2. **Traduction** : la question est traduite en anglais technique et sert de requête supplémentaire, car certains des manuels du corpus sont en anglais. Sans elle, une question en français dont la réponse est dans un manuel anglais (par exemple le paramètre `p3112`) ne serait pas trouvée.
3. **Recherche hybride** : FAISS (sens) et BM25 sans accents (termes exacts, petits manuels spécialisés) donnent chacun 50 candidats. Les deux classements sont fusionnés par Reciprocal Rank Fusion, et on garde 30 candidats. Si la question contient un code (`F07801`, `p3112`, `0x0006`), l'entrée de catalogue correspondante est toujours ajoutée en tête : pour un modèle de vecteurs, un code n'est qu'une suite de caractères.
4. **Re-ranking et diversité** : le cross-encoder note chaque paire (question, passage). On garde 5 passages, avec au plus 2 par manuel (pour que les gros manuels ne monopolisent pas les résultats) et 1 figure maximum.
5. **Génération** : les extraits sont numérotés `[Source n]` avec leur référence. Le modèle cite ces numéros (plus fiable pour un 3B que de recopier une référence longue), puis le code ajoute les références complètes et affiche les schémas rattachés aux sources citées.

On n'applique pas de seuil sur la similarité cosinus : on s'était aperçu que les questions hors corpus obtiennent une proximité moyenne **plus élevée** (0,877) que les questions du corpus (0,860).

3.2. Évaluation et limites constatées

Retriever. Le jeu `eval.jsonl`, construit par un plus gros LLM auquel on a donné le corpus, contient 55 questions, dont 3 hors périmètre. Un passage est jugé correct s'il est l'entrée du code attendu, ou s'il vient du bon manuel et contient un extrait de référence. On mesure le rang du premier bon passage sur les 52 questions du corpus, pour trois configurations ajoutées l'une après l'autre (Tableau 1).

La limite par manuel rend la place aux petits manuels (+3 manuels corrects dans le top 5). La traduction apporte le gain principal : +10 questions dont la réponse se trouve dans le top 5, en grande partie des questions CPU, trace et PROFINET dont les manuels sont en anglais. Il reste 8 questions sans bon passage, souvent des formulations éloignées du texte.

Bout en bout : Les 55 questions passent par l'agent complet, chacune dans une conversation neuve. Les réponses sont comparées à l'œil aux réponses attendues, et les refus sont vérifiés automatiquement. Un bon passage est transmis pour 44 des 52 questions du corpus, et le modèle de base ne fait aucun faux refus (0/52). Sur le fond, les réponses sont souvent justes quand le bon passage est présent (`F07801`, OB 82, SNMP, `r0945`). En revanche, le score de refus correct est de **0/3**, et trois défauts reviennent :

- **Format de refus non respecté** : sur les 3 questions hors périmètre (Allen-Bradley, S7-300, ABB), le modèle refuse bien sur le fond, mais avec une phrase longue (« La documentation fournie ne contient aucune information… Je vous recommande… ») au lieu de la formule exacte. La notation automatique compte ces refus comme des échecs.
- **Réponses trop longues** : le modèle paraphrase les extraits, fait des listes numérotées et des conclusions, et la réponse est parfois coupée au milieu d'une phrase par la limite de 300 tokens.
- **Citations irrégulières** : `[Source n]` est souvent oublié ou remplacé par une mention vague (« voir Source 4 »).

S'y ajoutent les limites du corpus : un schéma n'est retrouvé que par sa légende, pas par son contenu, et le jeu d'évaluation, généré par LLM, reste petit et peut contenir des erreurs.

4. Fine-tuning LoRA

Le but de notre fine-tuning était donc de corriger les trois défauts de comportement observés : des réponses **courtes et directes** (1 à 3 phrases), une **citation systématique** `[Source n]` après chaque information, et le **refus au format exact**.

Données : Des triplets (contexte, question, réponse) ont été générés par un LLM plus gros à partir des passages du corpus, sans fuite de questions entre les splits (Tableau 2). Le contexte reproduit exactement la sortie de la pipeline : les bons passages sont placés à une position aléatoire parmi des distracteurs trouvés par BM25. Les réponses sont en français, même à partir d'extraits anglais. Les refus couvrent quatre cas : d'autres marques (Altivar, KUKA…), des sujets hors domaine, des produits Siemens absents du corpus (LOGO!, S120…), et des codes réels dont le passage a été volontairement retiré du contexte, pour que le modèle n'apprenne pas à répondre à partir d'un code voisin.

Entraînement : les hyperparamètres sont donnés dans le Tableau 3. Un exemple contient beaucoup de tokens de prompt (prompt système, 5 extraits, question) pour peu de tokens de réponse. On **masque donc le prompt** dans les labels (valeur `-100`) : la loss ne porte que sur la réponse et le token de fin `<|im_end|>`, qui apprend au modèle à s'arrêter tôt. Seuls 5,8 % des

tokens du jeu d'entraînement (9 954 sur 170 725) comptent dans la loss. Sans ce masquage, le modèle passerait l'essentiel de l'entraînement à apprendre à prédire les extraits. Le rang 8 suffit, car il s'agit d'un changement de style et de format, pas d'une nouvelle langue ou d'un nouveau domaine. L'adaptateur n'entraîne que 15,0 M paramètres, soit 0,48 % des 3,1 G du modèle.

Surapprentissage : la loss d'entraînement est divisée par 6, mais la loss de validation est minimale dès la première époque (0,656), puis remonte jusqu'à 0,793 (Fig. 3, Tableau 4). Avec 200 exemples, le modèle mémorise les réponses d'entraînement dès la deuxième époque. L'adaptateur utilisé est celui de la fin de l'entraînement (époque 3). Une proposition pour améliorer cela : garder le checkpoint de l'époque 1 ou n'entraîner qu'une ou deux époques.

5. Résultats : baseline et modèle fine-tuné

Les 20 questions de `test.jsonl` (15 du corpus, 5 attendues hors périmètre) passent par la pipeline complète. Pour comparer les deux modèles à contexte égal, la recherche est faite une seule fois par question, puis chaque modèle génère sa réponse sur les mêmes 5 passages. Le retriever transmet au moins un bon passage pour 13 des 15 questions du corpus.

5.1. Évaluation automatique

La notation automatique (Tableau 5) mesure les trois comportements visés par le fine-tuning. Le LoRA cite ses sources sur toutes les questions du corpus (contre 6/15 pour la baseline). Ses réponses sont trois fois plus courtes, avec une longueur proche de celle des réponses de référence, et plus aucune n'est tronquée. Le refus exact passe de 1/5 à 3/5, sans aucun faux refus. Ces métriques ne vérifient cependant que la forme : elles ne disent pas si la réponse est juste, ni si `[Source n]` renvoie au bon passage.

Nous avons relu les 40 réponses (20 questions × 2 modèles) en les confrontant aux passages du corpus, avec une échelle de 0 à 2 par critère :

- **Pertinence et correction** : 2 = réponse juste et complète par rapport à la documentation ; 1 = partiellement juste (incomplète, imprécise ou mêlant une erreur mineure) ; 0 = fausse ou hors sujet.
- **Respect du rôle et du format** : on part de 2 et on retire 1 point par écart (réponse trop longue, c'est-à-dire plus de 3 phrases ou une liste ; citation `[Source n]` absente ou vague ; français dégradé ou réponse tronquée), sans descendre sous 0. Pour une question hors périmètre : 2 = formule de refus exacte, 1 = refus paraphrasé, 0 = réponse donnée.
- **Reconnaissance du hors-périmètre** : même échelle que le refus ci-dessus, sur les questions réellement hors corpus. On compte aussi les faux refus.
- **Informations inventées ou non vérifiables** : nombre de réponses contenant au moins une affirmation absente des passages ou contraire à eux.
- **Prise en compte de l'historique** : sur le dialogue multi-tours du notebook (`F07801` puis « Et comment je l'acquitte ? »), on note la reformulation de la question de suivi (0 à 2) et la réponse obtenue (0 à 2).

Bilan. Le fine-tuning atteint ses objectifs de forme : le score de format passe de 9/40 à 32/40 et la reconnaissance du hors-périmètre de 3/6 à 6/6. En contrepartie, la précision du contenu baisse (25/34 contre 29/34, et 8 réponses complètes contre 12). Le surapprentissage observé sur la loss de validation pourrait expliquer une partie de cette baisse.

6. Conclusion

La combinaison d'un RAG hybride orienté codes défaut, d'un décodage greedy et d'un LoRA léger (r = 8, 200 exemples, 3 époques) donne un assistant qui répond court, cite systémati-

quement ses sources et refuse proprement les questions hors périmètre. L'évaluation humaine montre toutefois que ce gain de forme se paie par des réponses moins précises et par davantage de petits détails inventés. Quatre pistes de progrès se dégagent. D'abord, améliorer le rappel du retriever (44/52 dans le top 5), qui conditionne la justesse des réponses. Ensuite, limiter le surapprentissage, en gardant le meilleur checkpoint et en enrichissant le jeu d'entraînement avec des procédures longues. Troisièmement, corriger le jeu de test (`F01600`, `A01900`) et vérifier les citations passage par passage. Enfin, évaluer l'historique avec le modèle fine-tuné. L'agent est utilisable dans une interface Gradio, depuis le notebook ou avec le script autonome `app.py`.

Annexes

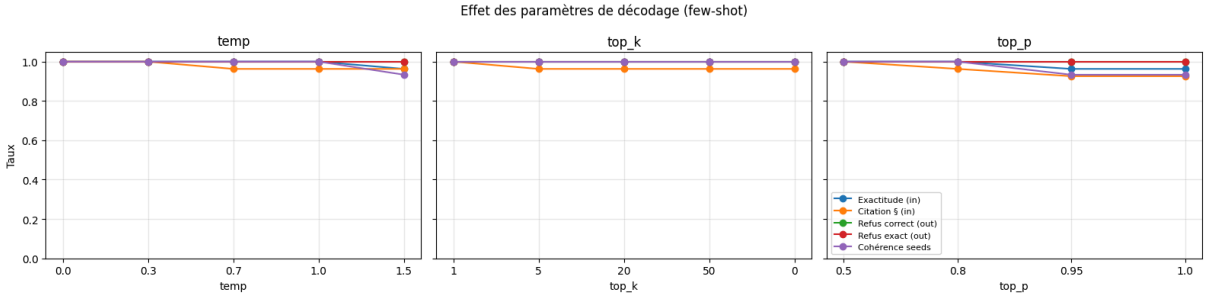


Fig. 1. – Effet de la température, de top-k et de top-p sur les métriques de la baseline (few-shot, 3 seeds).

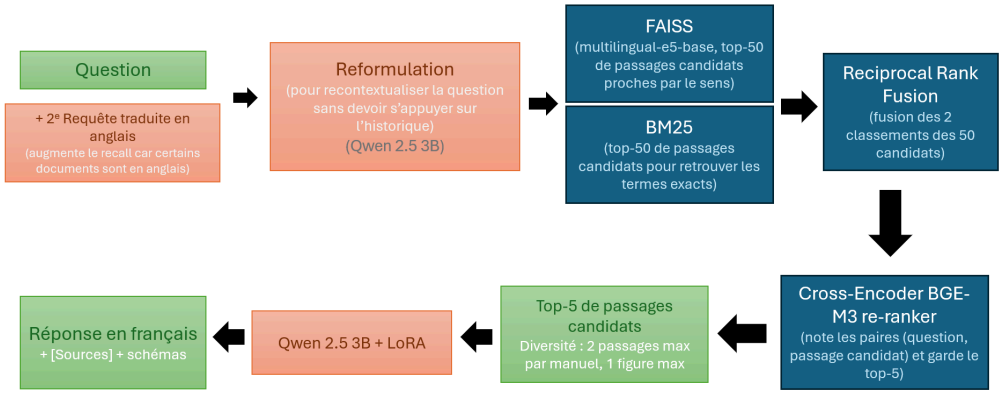


Fig. 2. – Architecture de la pipeline RAG de SiemDiag.

Configuration	Bon passage en 1re position	Bon passage dans le top 5	Bon manuel dans le top 5
Hybride + re-ranker	30/52	32/52	38/52
1. 2 passages max par manuel	30/52	34/52	41/52
1. traduction EN	**34/52**	**44/52**	**49/52**

Tableau 1. – Évaluation du retriever sur `eval.jsonl` (52 questions du corpus).

Split	Total	Avec sources	Refus	Multi-sources
train	200	160	40	8
val	20	15	5	3
test	20	15	5	2

Tableau 2. – Composition des jeux de données du fine-tuning.

Modèle de base	Qwen 2.5 3B Instruct, 4 bits NF4 (QLoRA)
LoRA	r = 8, α = 16, dropout 0,05, 7 modules linéaires (q, k, v, o, gate, up, down)
Entraînement	3 époques, lr 2e-4 (cosinus), batch effectif 8 (1 × 8), `paged_adamw_8bit`, fp16, gradient checkpointing
Loss	uniquement sur la réponse (prompt masqué à `-100`), séquences de 2 048 tokens au maximum

Tableau 3. – Hyperparamètres du fine-tuning LoRA.

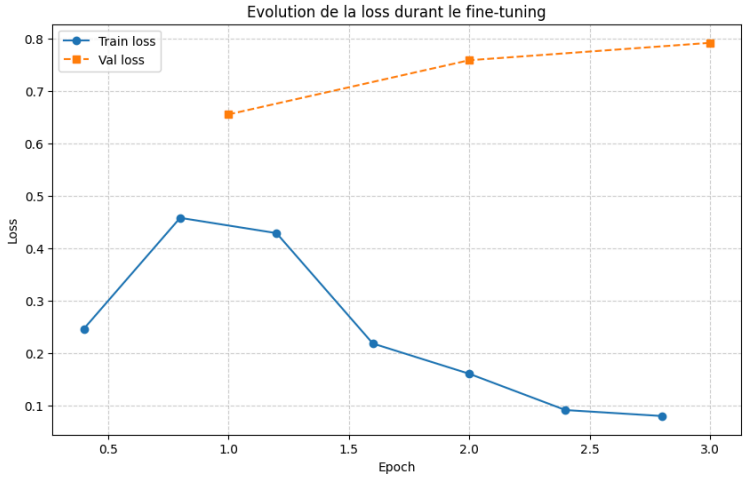


Fig. 3. – Évolution des loss d'entraînement et de validation pendant le fine-tuning.

Époque	Loss train	Loss val
1	0,458	**0,656**
2	0,160	0,759
3	0,079	0,793

Tableau 4. – Loss par époque : la validation est minimale à l'époque 1.

Métrique	Baseline	LoRA	Attendu
Sources citées, avec des numéros valides (questions du corpus)	6/15	**15/15**	—
Refus au format exact (hors périmètre)	1/5	**3/5**	—
Faux refus (questions du corpus)	0/15	0/15	—
Longueur moyenne des réponses (mots)	79,8	**26,9**	24,6

Tableau 5. – Évaluation automatique sur `test.jsonl`, avec les mêmes passages transmis aux deux modèles.

Critère	Échelle et périmètre	Baseline	LoRA
Pertinence et correction	0 à 2 par question, 17 questions du corpus	**29/34** (12 complètes)	25/34 (8 complètes)
Respect du rôle et du format	0 à 2 par question, 20 questions	9/40	**32/40**
Reconnaissance du hors-périmètre	0 à 2, 3 questions réellement hors corpus	3/6	**6/6**
Faux refus	nombre, 17 questions du corpus	0/17	0/17
Informations inventées ou non vérifiables	nombre de réponses concernées (↓ mieux), 20 questions	**3/20**	6/20
Prise en compte de l'historique	dialogue `F07801` (2 tours) : reformulation / réponse, 0 à 2 chacune	2/2 et 0/2	non mesuré

Tableau 6. – Synthèse de l'évaluation humaine sur `test.jsonl` (`F01600` et `A01900` comptés comme questions du corpus).

Question	Bon passage	Baseline			LoRA		
		Corr.	Format	Inventé	Corr.	Format	Inventé
`p0308` à 0	oui	1	1	—	1	1	oui
MRP interconnection	oui	2	0	—	1	1	—
`A50020` Shared Device	oui	2	0	—	2	2	—
PROFIenergy actif	non	1	0	—	1	2	oui
`F01600` acquittement	oui	2	0	—	2	2	—
Mappage HART en RUN	oui	1	1	—	1	1	—
`A07910` surchauffe	oui	2	0	—	2	2	—
`A08756` / `A08757` CANopen	oui	2	0	—	2	2	—
`A02058` / `A02059` traces	oui	2	0	—	2	1	—
`A01900` PROFIBUS	oui	1	0	oui	2	2	—
Groupe d'alarmes	oui	2	1	—	2	1	—
Couches du firewall	oui	2	0	—	2	1	—
Transfert carte mémoire	oui	2	0	—	1	2	oui
Temps de frein par défaut	oui*	2	0	—	1	2	oui
Web API −32602	oui	2	2	—	1	1	oui
Sauvegardes sur carte	oui	2	1	—	1	1	oui
Validité des voies	oui	1	0	oui	1	2	—
Questions réellement hors périmètre (format = reconnaissance du hors-périmètre)							
Coupe du monde FIFA	—	—	2	—	—	2	—
SINAMICS S120	—	—	0	oui	—	2	—
LOGO! 8	—	—	1	—	—	2	—

Tableau 7. – Notes de l'évaluation humaine par question. Corr. = pertinence et correction (0 à 2), Format = rôle et format (0 à 2), Inventé = au moins une affirmation absente des passages ou contraire à eux. * Le passage attendu n'est pas récupéré, mais la même information est transmise par une autre entrée du List Manual (p.162).